M2.851 – Tipología y ciclo de vida de los datos. Aula 2. PRA 1

Aleix Salvador Barrera y Víctor Miranda Hernández.

Ejercicio 1 [0,25 puntos]

Contexto. Explicar en qué contexto se ha recolectado la información. Explique por qué el sitio web elegido proporciona dicha información.

El objetivo de esta práctica nace de la necesidad de encontrar datos contenidos en una web y a partir de ellos construir un dataset. Se ha escogido la web de www.meteopozuelo.es ya que permite recoger datos con profundidad histórica y con diferente información relacionada con la meteorología. Más adelante en este documento se detallará como es el proceso de recolección de datos y su tipología.

Ejercicio 2 [0,25 puntos]

Definir un título para el dataset. Elegir un título que sea descriptivo.

El título que definimos para el dataset extraído mediante web scraping en esta primera práctica de la asignatura es: "Datos meteorológicos de Pozuelo de Alarcón (Madrid)".

Ejercicio 3 [0,25 puntos]

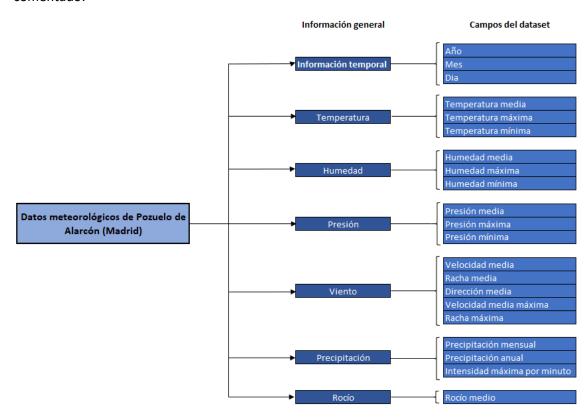
Descripción del dataset. Desarrollar una descripción breve del conjunto de datos que se ha extraído (es necesario que esta descripción tenga sentido con el título elegido).

El conjunto de datos que se ha extraído en esta práctica está compuesto por una serie de indicadores meteorológicos diarios recogidos por la estación meteorológica de Pozuelo de Alarcón situada en el área metropolitana de la ciudad de Madrid. Estos indicadores están comprendidos entre el mes de febrero de 2018 y el mes de febrero de 2021.

Ejercicio 4 [0,25 puntos]

Representación gráfica. Presentar esquema o diagrama que identifique el dataset visualmente y el proyecto elegido.

Para representar gráficamente el dataset se ha construido un esquema en el que se identifica cada uno de los campos. Además, estos campos están segmentados según el elemento del clima al que hacen referencia (humedad, temperatura, etc). A continuación se adjunta el esquema comentado:



Ejercicio 5 [1 punto]

Contenido. Explicar los campos que incluye el dataset, el periodo de tiempo de los datos y cómo se ha recogido.

El dataset extraído contiene 21 campos. A continuación se detallará el contenido de cada uno de ellos:

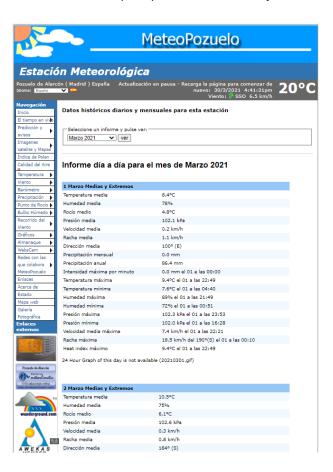
- Dia: número del día de la fecha en cuestión.
- Mes: nombre del mes de la fecha en cuestión.
- Año: año de la fecha en cuestión.
- Temperatura media: temperatura media, en ºC, de la fecha en cuestión.
- Humedad media: humedad media, en %, de la fecha en cuestión.
- Rocío medio: rocío medio, en ºC, de la fecha en cuestión.
- Presión media: presión atmosférica media, en kPa, de la fecha en cuestión.
- Velocidad media: velocidad media del viento, en km/h, de la fecha en cuestión.
- Racha media: racha media de viento, en km/h, de la fecha en cuestión.
- Dirección media: dirección del viento media, en º + punto cardinal, de la fecha en cuestión.
- Precipitación mensual: precipitación mensual acumulada, en mm, de la fecha en cuestión.
- Precipitación anual: precipitación anual acumulada, en mm, de la fecha en cuestión.
- Intensidad máxima por minuto: intensidad máxima de precipitación, en mm, de la fecha en cuestión y momento del día en el que se ha producido..
- Temperatura máxima: temperatura máxima, en ºC, de la fecha en cuestión y momento del día en el que se ha producido.
- Temperatura mínima: temperatura mínima, en °C, de la fecha en cuestión y momento del día en el que se ha producido.
- Humedad máxima: humedad máxima, en %, de la fecha en cuestión y momento del día en el que se ha producido.
- Humedad mínima: humedad mínima, en %, de la fecha en cuestión y momento del día en el que se ha producido.
- Presión máxima: presión atmosférica máxima, en kPa, de la fecha en cuestión y momento del día en el que se ha producido.
- Presión mínima: presión atmosférica mínima, en kPa, de la fecha en cuestión y momento del día en el que se ha producido.
- Velocidad media máxima: velocidad media máxima del viento, en km/h, de la fecha en cuestión y momento del día en el que se ha producido.
- Racha máxima: racha de viento máxima, en km/h, de la fecha en cuestión y momento del día en el que se ha producido.

Por otro lado, los datos están comprendidos dentro del período que abarca entre el mes de febrero de 2018 y el mes de febrero de 2021.

Finalmente, se resumirá el procedimiento seguido para la recogida de la información (en el ejercicio 9 se entrará en detalle en cada una de las partes del código utilizado):

 En primer lugar se debe destacar que la página que hemos utilizado de la web de la estación meteorológica de Pozuelo de Alarcón (Madrid) está dispuesta de forma que los últimos 6 dígitos de la URL marcan el mes para el cual se muestran los datos. Este hecho nos ha facilitado las cosas porque de esta forma es mucho más sencillo iterar sobre la página para obtener la información de diferentes meses. En los próximos puntos se detallará el proceso realizado para la obtención de la información.

- El web scraping que hemos realizado en esta práctica para obtener los datos de la estación meteorológica de Pozuelo de Alarcón se basa en dos iteraciones. En primer lugar se itera sobre los meses que se desea obtener la información, y después, dentro de cada mes, se itera para obtener la información de cada uno de los días de dicho mes.
- A continuación se adjunta una captura de pantalla de la disposición de la página desde la cual se ha extraído la información para poder entender mejor la metodología seguida:



En la captura de pantalla se puede observar que la información de cada día del mes que se haya seleccionado se encuentra en diferentes tablas. Por lo tanto, para acceder a ellas se ha realizado el comando "find_all('table')" de Python con el fin de obtener una lista con la información de cada una de las tablas. Después de esto se ha recorrido cada uno de los elementos de la lista comentada (es decir, cada uno de los días) y se ha extraído la información que hay dentro.

• Después de obtener la información en una lista, se ha creado un archivo csv con la sentencia "csv.writer" de Python.

Ejercicio 6 [1,5 puntos]

Agradecimientos. Presentar al propietario del conjunto de datos. Es necesario incluir citas de análisis anteriores o, en caso de no haberlas, justificar esta búsqueda con análisis similares.

El propietario de los datos es la estación meteorológica del municipio de Pozuelo de Alarcón. Desde este observatorio meteorológico se recogen variables climatológicas como la presión, humedad, temperatura o la velocidad del viento. La estación meteorológica está integrada en meteoclimatic, una red de estaciones automáticas distribuidas por la península ibérica.

A continuación, se presentan un análisis de datos meteorológicos encontrado en Internet para mostrar que tipo de análisis se pueden desarrollar con esta temática de datos.

 Análisis estadístico de datos meteorológicos mensuales y diarios para la determinación de variabilidad climática y cambio climático en Quito, elaborado por la Universidad Politécnica Salesiana Cuenda de Ecuador. A partir de los datos recogidos por las estaciones meteorológicas de Quito y de variables como las que se recogerán en esta práctica, se analizan los cambios en las condiciones climáticas a lo largo de los años.

Se escoge este análisis ya que el propietario del conjunto de datos no presenta ningún estudio sobre sus propios datos. El ejemplo propuesto se asemeja debido a que estudia las mismas variables a partir de también estaciones meteorológicas y puede servir como referencia.

Ejercicio 7 [1,5 puntos]

Inspiración. Explique por qué es interesante este conjunto de datos y qué preguntas se pretenden responder. Es necesario comparar con los análisis anteriores presentados en el apartado 6.

Según nuestro punto de vista, este conjunto de datos es interesante debido a la importancia que tienen los factores meteorológicos para cualquier ámbito del planeta y por lo tanto también de los humanos. En la actualidad hay pocos temas más importantes y recurrentes que el cambio climático y sus efectos y consecuencias. Por estos motivos y por la facilidad de encontrar más de una variable que analizar con profundidad histórica, se ha escogido esta temática.

Se pretende responder preguntas como las siguientes:

- ¿Cuál es la evolución de las condiciones meteorológicas a lo largo de los años recogidos?
- ¿Se pueden evidenciar con los datos analizados los efectos del cambio climático?
- ¿Como se relacionan las variables estudiadas entre ellas?

Además, a lo largo de las prácticas pueden ir surgiendo diferentes preguntas extra como podría ser que variables de las estudiadas presentan más estacionalidad o si se podría hacer una estimación de alguna de ellas a partir de las restantes. Otro posible análisis comentado por los integrantes del grupo es el de si seria interesante cruzar la información con otras temáticas sociales o económicas para observar efectos de la meteorología en el comportamiento de la sociedad o economía.

Se considera que se puede comparar con el ejemplo mencionado en el ejercicio 6 por las razones comentadas, la similitud de las variables y la idea de analizar el cambio climático y como ha ido variando las condiciones climáticas a lo largo de los años.

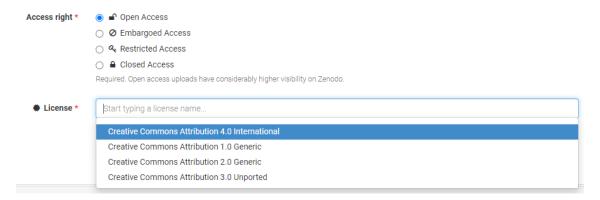
Ejercicio 8 [1 punto]

Licencia. Seleccione una de estas licencias para su dataset y explique el motivo de su selección:

- Released Under CCO: Public Domain License
- Released Under CC BY-NC-SA 4.0 License
- Released Under CC BY-SA 4.0 License
- Database released under Open Database License, individual contents under Database Contents License
- Other (specified above)
- Unknown License

La licencia que seleccionamos nosotros para nuestro dataset no se encuentra entre las opciones especificadas en el enunciado. Destacar que la que hemos seleccionado es: Released Under CC BY 4.0 License. Los motivos de la selección de esta licencia son dos:

• En primer lugar, al publicar el dataset en Zenodo únicamente podíamos seleccionar las cuatro licencias que aparecen en la siguiente captura de pantalla:



• En segundo lugar, al visualizar las licencias posibles, hemos investigado en qué se caracterizaba cada una de ellas y hemos seleccionado la "Creative Commons Atribution 4.0 International" porque es la que más se adaptaba a nuestras intenciones, ya que permite a los futuros usuarios del dataset copiar y redistribuirlo así como transformarlo y adaptarlo para cualquier propósito. Finalmente, destacar que en ningún momento hemos tenido la intención de publicar el dataset de forma restringida ya que contiene ningún tipo de información confidencial y, por lo tanto, puede servir de ayuda a cualquier futuro análisis que se pueda realizar.

Ejercicio 9 [2 puntos]

Código. Adjuntar el código con el que se ha generado el dataset, preferiblemente en Python o, alternativamente, en R.

En este ejercicio se adjuntará el código de Python con el que se ha generado el dataset (se adjunta mediante tres imágenes porque no cabe en una sola captura de pantalla):

```
Jupyter PRACTICA1 Salvador Miranda Last Checkpoint: hace unos segundos (autosaved)
                                                                                                                                                                  Logout
File Edit View Insert Cell Kernel Widgets Help
                                                                                                                                                  Trusted Python 3 O
In [1]: ### IMPORTACIÓN DE LAS LIBRERÍAS NECESARIAS PARA EJECUTAR NUESTRO CÓDIGO
                 import os
                 import requests
                 import csv
from datetime import datetime
                 from datetime import timedelta from bs4 import BeautifulSoup
                 from dateutil.relativedelta import *
                 ### DEFINICIÓN DE LA FUNCIÓN MEDIANTE LA CUAL SE REALIZARÁ EL WEB SCRAPING
                 def meteoPozuelo(url,mes_min,mes_max):
                     mes min date = datetime.strptime(mes min."%m/%y") ##Mayor o iqual a diciembre de 2011
                     mes_max_date = datetime.strptime(mes_max,"%m/%Y") ##Menor o igual al mes en curso (abril de 2021)
                     dd = [] #Se crea una lista vacía donde se recopilará la información que se extrae de la web
                      campos = ["Dia","Mes","Año","Temperatura media","Humedad media","Rocío medio","Presión media","Velocidad media",
    "Racha media","Dirección media","Precipitación mensual","Precipitación anual","Intensidad máxima por minuto",
                        "Temperatura máxima","Temperatura mínima","Humedad máxima","Humedad mínima","Presión máxima","Presión mínima",
"Velocidad media máxima","Racha máxima"] #lista con los nombres de los campos a recopilar
                      dd.append(campos) #el primer elemento de dd son los nombres de los campos a recopilar
                     while mes_min_date <= mes_max_date:
                          mes_min_YYYYMM = str(mes_min_date.year) + mes_min_date.strftime('%m')
                          url_complet = url + mes_min_YYYYMM
                          page = requests.get(url complet)
                          soup = BeautifulSoup(page.content,"html.parser")
                          datos = soup.find_all('table')
                          datos = datos[:-3] #Eliminamos los tres últimos valores de la lista "datos" porque son tres tablas de datos
#globales de todo el mes de temperatura y precipitaciones que no nos interesan en el estudio
```

```
mes_max = '02/2021' #Mes máximo a cargar en formato MM/YYYY

dataset = meteoPozuelo(url,mes_min,mes_max)

directorio_actual = os.getcwd()

nombre_archivo = "datos_meteorologicos_pozuelo_dataset.csv"

ruta_archivo = os.path.join(directorio_actual,nombre_archivo)

with open(ruta_archivo,'w',newline='') as archivo_csv:
    writer = csv.writer(archivo_csv, delimiter=';')
    for i in dataset:
        writer.writerow(i)
```

En el código adjuntado podemos distinguir tres partes claramente seccionadas: la importación de las librerías necesarias, la definición de la función que extrae la información de la página web escogida y finalmente la ejecución de la función y creación del archivo csv que contiene el dataset creado. A continuación se detallarán los procedimientos seguidos en cada una de estas tres partes:

• Importación de las librerías necesarias.

En esta parte del código se han importado las librerías "datetime", "timedelta" y "relativedelta" para trabajar con fechas, las librerías "requests" y "BeautifulSoup" para realizar el web scraping, la librería "csv" para crear el archivo csv que contiene el dataset obtenido, y la librería "os" para trabajar con las rutas de carpetas del pc.

• Definción de la función "meteoPozuelo".

En esta segunda parte del código se ha definido la función "meteoPozuelo" que nos ayudará a obtener la información mediante web scraping de la página web de la estación meteorológica de Pozuelo de Alarcón. Esta función tiene los parámetros "url", "mes_min" y "mes_max" que corresponden a la URL de la página web comentada (sin los 6 últimos dígitos, que son los que corresponden al mes cuya información se desea visualizar) y los meses mínimo y máximo que se quieren incluir al dataset (en formato 'MM/YYYY') respectivamente. A continuación se detallan los cálculos y pasos que se realizan dentro de la función:

- En primer lugar se calculan las variables "mes_min_date" y "mes_max_date" a partir de los parámetros "mes_min" y "mes_max" de la función. Básicamente estas dos variables son el resultado de coger los parámetros de la función (que están en formato string) y pasarlos a formado "date".
- En segundo lugar se crea una lista vacía llamada "dd", la cual se irá llenando con la información extraída mediante el web scraping. También se crea una lista llamada "campos" con los nombres de los campos que tendrá el dataset y se adjunta como primer valor de la lista "dd" creada anteriormente. De esta forma se obtendrán los nombres de los campos del dataset como primer valor de la lista dd, y posteriormente se irá insertando la información de estos campos.
- En tercer lugar se realiza un bucle "while" de forma que se irá iterando mientras el valor de la variable "mes_min_date" sea inferior que el de la variable "mes_max_date".
- Ya dentro del bucle, en primer lugar creamos la variable "mes_min_YYYYMM". Esta variable contendrá el año y el número de mes concatenados (es decir, para el mes de enero de 2020 valdrá 202001). Después se crea la variable "url_complet" que será el resultado de concatenar el parámetro de la función "url" con la variable

"mes_min_YYYYMM" que se acaba de calcular, con el fin de obtener la URL completa de la web de la estación meteorológica donde se encuentran los datos del mes en cuestión.

- Después de obtener la URL completa, se realiza el web scraping. Para ello se ejecuta la sentencia "requests.get(url_complet)" para obtener la web que se está solicitando. Una vez hecho esto, se ejecuta la función "BeautifulSoup" para obtener el código fuente de dicha web, y finalmente se ejecuta la sentencia "find_all('table')" para obtener las partes de este código fuente que estén dentro de 'table', es decir, la información que queremos extraer (recordar que la información en la página web se encontraba dentro de tablas de datos y por eso buscamos por la palabra 'table').
- Una vez se ha obtenido la información resultante de la sentencia "find_all('table')" se borran los tres últimos elementos de la lista ya que son tres tablas con estadísticas globales del mes en cuestión, las cuales no nos interesan porque únicamente queremos la información diaria.
- Después de borrar los tres últimos elementos de la lista "datos" (en la cual se encuentra la información de cada día del mes en cuestión) se realiza un bucle "for" para recorrer cada uno de los elementos de "datos" (es decir, cada uno de los días del mes en cuestión) y en cada una de estas iteraciones se saca la información que deseamos mediante los cálculos que se muestran en la captura de pantalla.
- Finalmente, creamos una lista llamada "dd_diaX" con la información recopilada del día referente a la iteración que estamos realizando y se juntan a la lista "dd" que hemos creado antes de empezar el bucle principal "while".
- Por último, actualizamos la variable "mes_min_date" añadiéndole un mes. Después de esto se vuelve arriba del while y se comprueba si esta variable "mes_min_date" actualizada es menor o igual a la variable "mes_max_date" y vuelta a empezar.
- Ejecución de la función "meteoPozuelo" y creación del archivo csv.

Después de definir la función "meteoPozuelo" se realiza su ejecución utilizando como parámetros las variables "url", "mes_min" y "mes_max" que se crean en esta tercera parte.

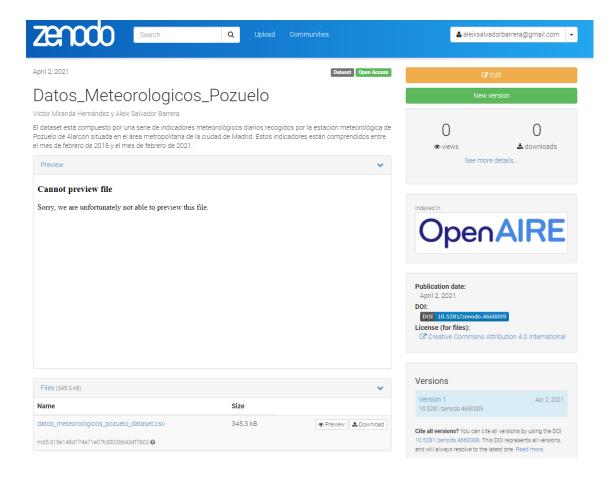
Antes de terminar, se crea la ruta donde se creará el archivo csv con el dataset obtenido mediante la concatenación de la ruta del directorio actual y el nombre que le queramos dar al archivo csv.

Finalmente, se crea el archivo csv en la ruta especificada mediante la función "csv.writer".

Ejercicio 10 [2 puntos]

Dataset. Publicación del dataset en formato CSV en Zenodo (obtención del DOI) con una breve descripción.

Para finalizar la práctica se ha publicado el dataset en formato CSV en Zenodo. El DOI obtenido en la publicación es: 10.5281/zenodo.4660009. A continuación adjuntamos una captura de pantalla a modo de comprobación de que la publicación se ha realizado correctamente.



Para finalizar, también se adjunta la URL de acceso a la página de Zenodo donde se ha publicado el dataset: https://zenodo.org/record/4660009#. YGwcgOgzaUk

Contribuciones	Firma
Investigación previa	ASB,VMH
Redacción de las respuestas	ASB,VMH
Desarrollo del código	ASB,VMH